# Introducción al tratamiento de textos (unix, python, perl, nltk, ...)



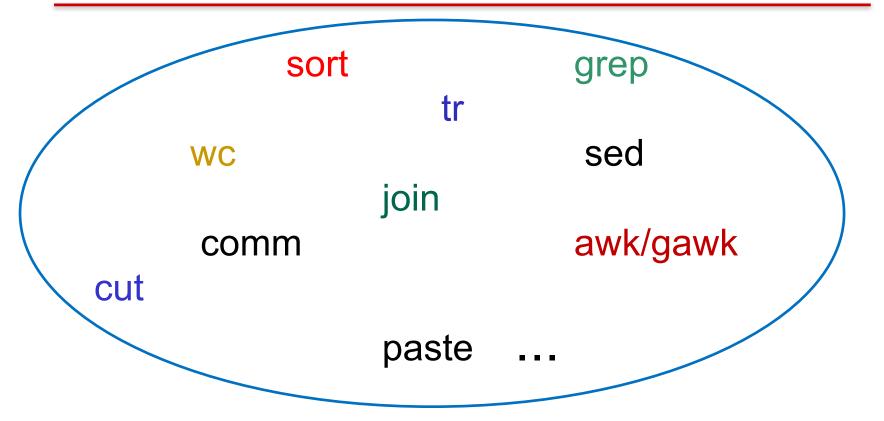


Lingüística Computacional

# Introducción

- Para el tratamiento de grandes colecciones de textos es conveniente el uso de lenguajes potentes y "fáciles" para la manipulación de cadenas.
- En este tema nos vamos a centrar en presentar, sin que sea esto un curso de programación, el lenguaje Python, incidiendo en las estructuras/clases y métodos útiles para la manipulación de textos.

## "Unix for Poets"



#### **Unix for Poets**

Kenneth Ward Church AT&T Bell Laboratories

http://www.stanford.edu/class/cs124/kwc-unix-for-poets.pdf http://ufal.mff.cuni.cz/~hladka/tutorial/UnixforPoets.pdf

# Ejemplo

Salgo de #VeoTV , que día más largoooooo ...

@PauladeLasHeras No te libraras de ayudar me/nos . Besos y gracias@marodriguezb Gracias MAR

Off pensando en el regalito Sinde , la que se va de la SGAE cuando se van sus corruptos . Intento no sacar conclusiones ( lo intento ) Conozco a alguien q es adicto al drama ! Ja ja ja te suena d algo !

Toca @crackoviadeTV3 . Grabación dl especial Navideño ... Mari crismas !

Rajoy , 3-1 para el Madrid ; Zapatero para " su " Barça y Rubalcaba evita " mojarse " - ABC . es http://t.co/LxBXidLx via @abc\_es

Eso es ;-) RT @ccifuentes : @JuananSanzNunez Por supuesto que nos veremos en #Sevilla , un besazo :-) @mariviromero Eso es ;-) )

Veeeeenga ..... Hagamos porra !!! Quién se lleva el partido ??

cat text.tx | gawk '{for (i=1;i<=NF;i++) print \$i;}' | sort | uniq -c | sort -nr>freq.txt

cat text.tx | gawk '{for (i=1;i<=NF;i++) print \$i;}' | sort | uniq -c | sort -nr| grep '.\*e\$'

freq.tx

4 es
4"
4.
4,
3 se
3 que
3 el
3 de
3!
2 y

# **Python**

http://python.org/

## Python 3.x

https://docs.python.org/3/

- Lenguaje creado por Guido Van Rossum en Holanda en 1991.
- Lenguaje interpretado multi-plataforma, orientado a objetos.
- Resulta muy adecuado para la manipulación de textos.

#### **Tutoriales**

Buscad por la red

# ¿Cómo editar/ejecutar un programa Python?

```
Eile Edit Shell Debug Options Windows Help Modo Interactivo

Python 2.7.3 (default, Aug 1 2012, 05:16:07)

[GCC 4.6.3] on linux2

Type "copyright", "credits" or "license()" for more information.

>>> for i in range(10):
    print i,

0 1 2 3 4 5 6 7 8 9

>>>
```



#### ¿Qué editor utilizar?

- Python lleva su propio IDLE
- Elige tu editor preferido, en tu SO.
- Importante: que gestione bien la identación , la sintaxis y la codificación del texto

# Distribución python: Anaconda

https://docs.anaconda.com/anaconda/

## **Anaconda Distribution**

Open Data Science Core

Anaconda® is a package manager, an environment manager, a Python distribution, and a collection of <u>over 720 open source</u> <u>packages</u>. It is free and easy to install, and it offers <u>free community support</u>.

Get the Anaconda Cheat Sheet and then download Anaconda.

Don't want the huge collection of 720 software packages? Get Miniconda.

## **NLTK**

http://www.nltk.org/

## NLTK 3.2.4 documentation

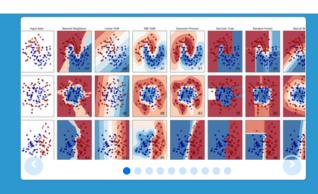
NEXT | MODULES | INDEX

## Natural Language Toolkit

NLTK is a leading platform for building Python programs to work with human language data. It provides easy-to-use interfaces to <u>over 50 corpora and lexical resources</u> such as WordNet, along with a suite of text processing libraries for classification, tokenization, stemming, tagging, parsing, and semantic reasoning, wrappers for industrial-strength NLP libraries, and an active <u>discussion forum</u>.

## scikit-learn

### http://scikit-learn.org/stable/



## scikit-learn

Machine Learning in Python

- Simple and efficient tools for data mining and data analysis
- Accessible to everybody, and reusable in various contexts
- · Built on NumPy, SciPy, and matplotlib
- Open source, commercially usable BSD license

#### Classification

Identifying to which category an object belongs to.

**Applications**: Spam detection, Image recognition.

Algorithms: SVM, nearest neighbors,

random forest, ... - Examples

#### Regression

Predicting a continuous-valued attribute associated with an object.

**Applications**: Drug response, Stock prices. **Algorithms**: SVR, ridge regression, Lasso,

Examples

#### Clustering

Automatic grouping of similar objects into sets.

**Applications**: Customer segmentation, Grouping experiment outcomes

Algorithms: k-Means, spectral clustering, mean-shift, ... — Examples

#### **Dimensionality reduction**

Reducing the number of random variables to consider.

Applications: Visualization, Increased

efficiency

**Algorithms**: PCA, feature selection, nonnegative matrix factorization. — Examples

#### **Model selection**

Comparing, validating and choosing parameters and models.

Goal: Improved accuracy via parameter

tuning

Modules: grid search, cross validation,

metrics. - Examples

#### **Preprocessing**

Feature extraction and normalization.

**Application**: Transforming input data such as text for use with machine learning algorithms. **Modules**: preprocessing, feature extraction.

Examples